PUBLIC DATA • END-TO-END ANALYTICS

Online Retail II 商业分析报告

英国在线零售商 2009–2011 交易数据 · SQL 查询 → Python 清洗与 EDA → Excel / Power BI 看板 → 5 条业务结论

£18.98M 净销售额	**39,516** 有效订单	**5,852** 客户数
2.41% 常规退货率	**85.5%** 英国营收占比	**15.3%** 海外市场同比

数据源：UCI Machine Learning Repository — Online Retail II（公开数据集）
分析范围：2009-12-01 至 2011-12-09 · 货币：英镑（£） · 粒度：订单行
项目入口：index.html · Excel：outputs/Online_Retail_II_商业分析看板.xlsx · Power BI：powerbi/OnlineRetailII/OnlineRetailII.pbip

01 数据与方法

目标不是“把数据画出来”，而是建立一套可核对、可复现、能支持经营决策的分析链路。

SQL

画像与抽取

DuckDB 对 1,067,371 行做字段画像、重复识别和跨表重叠检查；用 ROW_NUMBER 只删除 2010-12 重叠期的跨表重复，保留同表内可能的真实重复录入。

Python

清洗与探索

统一 SKU 大小写、补全缺失描述、拆分商品销售/退货、标记特殊 SKU 与价格异常；构建月度、国家、SKU、RFM、cohort、ABC 等分析表。

数据质量指标	数值	说明
原始行数	1,067,371	两张年度工作表合并
跨表重复删除	22,844	仅处理 2010-12 重叠期
清洗后行数	1,044,527	保留同表内重复记录
原始缺少客户 ID 行数	243,007	占原始行约 22.8%
清洗后缺少客户 ID 行数	235,286	不参与客户级 RFM
缺货品描述（清洗前）	4,382	按 SKU 众数描述补全
商品取消/退货行	17,974	含 C 开头发票与负数量
有效商品销售行	1,014,768	排除运费/手续费/手工调整
价格异常标记行	11	仅标记，不删除营收

销售口径

非取消发票、数量 > 0、单价 > 0、非运费/手续费/调整等特殊 SKU；净销售额 = 销售 − 退货。

客户口径

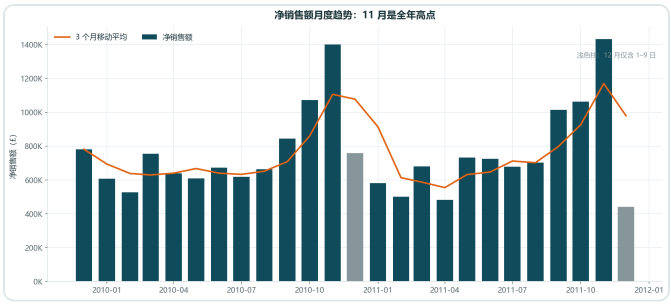
RFM 只覆盖有 Customer ID 的 5,852 位客户；游客订单仍计入整体营收，但不进入客群分析。

退货口径

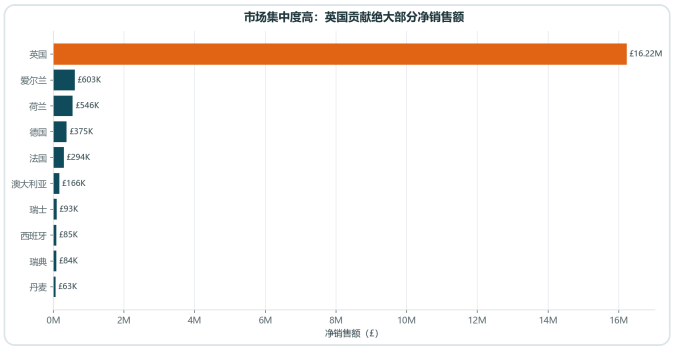
同时展示“全部退货率”和“剔除两笔批量退货后的常规退货率”，避免单笔批发取消扭曲商品质量判断。

02 经营表现

营收在 11 月集中爆发，市场高度集中于英国，海外是更快的增量来源。



月度净销售额：完整月份中 11 月平均为月均的 1.83 倍



市场集中度：英国 £16.22M，占 85.5%

结论 1 • Q4 峰值明确，增长高度依赖 11 月

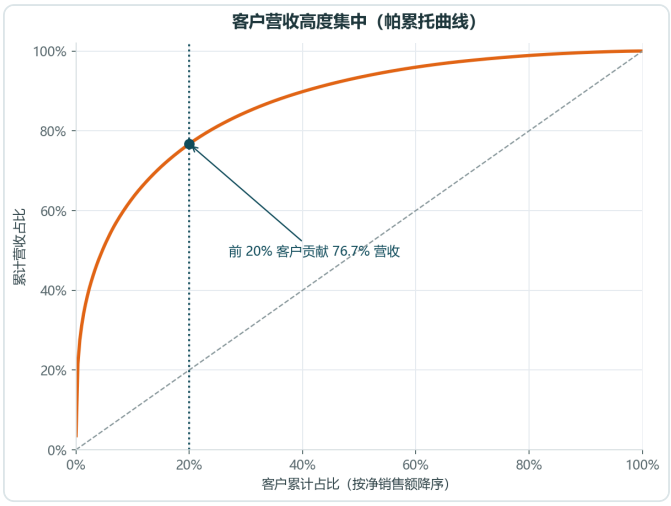
22 个完整月份中，11 月净销售额平均为月均的 **1.83 倍**；2011-11 净销售额 £1.43M。建议将旺季备货、临时客服与仓配能力前置到 9–10 月，对 A 类 SKU 设置 11 月安全库存。

结论 2 • 海外市场是主要增量

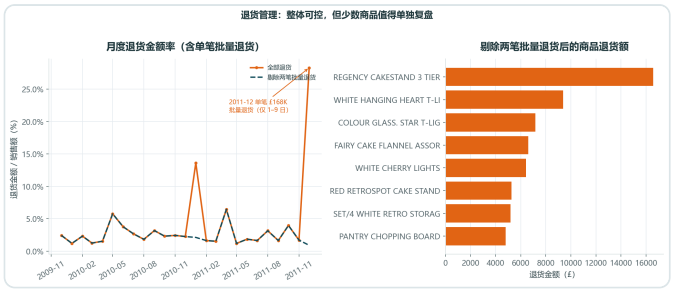
非英国市场同比 **+15.3%**，英国仅 +0.4%；法国 +54.9%、德国 +10.5%、荷兰 +10.9%。建议优先深耕法国、德国、荷兰，先验证澳大利亚的可持续复购。

03 客户、商品与退货

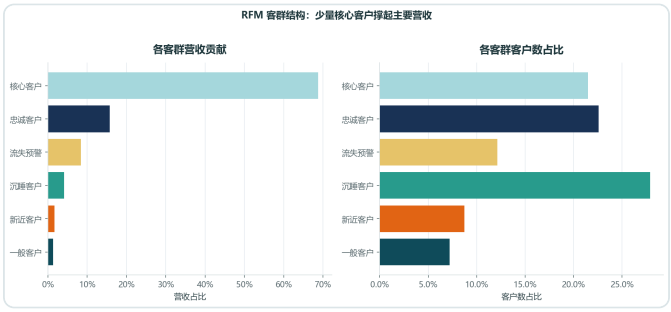
客户与商品都呈明显的“少数贡献多数”；退货需要区分批量取消与常规商品退货。



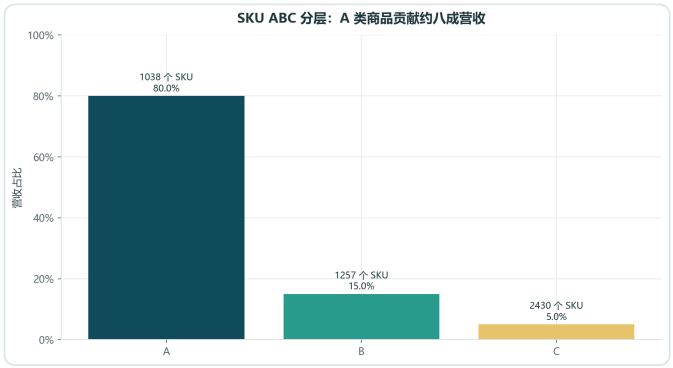
前 20% 客户贡献 76.7% 净销售额



全部退货率 3.65%；剔除两笔批量退货后 2.41%



核心客户 21.5% 人数，贡献 68.7% 营收



A 类 1,038 个 SKU 贡献 80% 营收

结论 3 • 客户集中度高，核心客户是营收基本盘

前 1% 客户贡献 **31.1%**，前 20% 客户贡献 **76.7%**；核心客户以 21.5% 的人数贡献 68.8% 营收。建议建立核心客户专属服务与补货提醒，对流失预警客群（12.1% 人数、8.4% 营收）做召回。

结论 4 • 退货整体可控，但被少数批量退货放大

全部退货金额率 **3.65%**；两笔批量退货合计 £245.7K，占退货额 34.1%；剔除后常规退货率 **2.41%**。建议将批发取消/整单退货与消费者退货分开考核。

结论 5 • 商品组合呈典型长尾

1,038 个 A 类 SKU 贡献 80.0% 营收；前 20% SKU 贡献 77.9%；2,430 个 C 类 SKU 仅贡献 5.0%。建议 A 类保供保曝光、B 类做组合与价格测试、C 类按动销与退货率逐步淘汰。

04 交付物与复现

同一套指标口径贯穿 SQL、Python、Excel 与 Power BI；所有图表与数字均可由脚本重建。

Excel 看板

outputs/Online_Retail_II_商业分析看板.xlsx
8 个工作表：首页、管理看板、客户分析、商品与退货、市场分析、业务结论、数据附表、数据字典。

Power BI 工程

powerbi/OnlineRetailII/OnlineRetailII.pbip
TMDL 语义模型、2 页 PBIR 报表、14 个 DAX 指标；用 Power BI Desktop 打开并刷新。

项目入口

index.html
汇总所有交付物链接、关键图表、结论与复现步骤，适合作为作品集首页。

复现命令

```
cd retail-analytics
python python/01_ingest.py
python python/02_sql_pipeline.py --full
python python/03_clean_eda.py
python python/04_build_excel.py
python python/06_build_powerbi.py
python python/07_validate_powerbi.py
```

Power BI 打开说明

使用 Power BI Desktop 打开 **OnlineRetailII.pbip**。若数据目录不同，在“转换数据 → 管理参数”中把 **DataPath** 改为本机 **data/processed** 的绝对路径，然后刷新。PBIR 报表 JSON 已通过微软官方 Schema 校验，28 个字段/度量引用均已在 TMDL 模型中核对。

数据源与说明

UCI Machine Learning Repository — Online Retail II。原始数据包含两张年度表，2010-12 有 9 天重叠；本报告只删除跨表重复，保留同表内重复记录。项目仅用于分析与作品展示。